模型融合保护方法研究进展

2026 年 10 月 23 日

1 研究问题与实验设置

目标是在不重新训练原专家的条件下处理其参数：发布模型单独使用时仍能完成原任务，未经授权与其他专家融合后，受保护任务的准确率显著下降。设公开基座、目标专家、伙伴专家和发布模型分别为 $\theta_0, \theta_e, \theta_p, \widetilde{\theta}_e$。独立能力与融合保护分别通过完整测试集评价，不以参数距离代替准确率。

主实验采用 Task Arithmetic（TA）[3]：

$$\theta_{\mathrm{m}} = \theta_0 + \lambda\big[(\widetilde{\theta}_e - \theta_0) + (\theta_p - \theta_0)\big], \qquad \lambda = 0.5. \tag{1}$$

双专家情形因此等于两份专家参数的平均。所有方法使用相同的 CLIP ViT-B/32 骨干、分类头和完整测试划分。

表 1　任务与评价规模

数据集	任务	类别数	完整测试样本数
MNIST	手写数字	10	10,000
DTD	纹理分类	47	1,880
SVHN	街景数字	10	26,032

原版 AGA[1] 可以访问发布模型和公开基座，不预先知道所用防御。评价分为三列：直接融合；只恢复保护专家后融合；对双方专家分别恢复后融合。AGA 源码固定在作者仓库的 `fb61429` 提交，没有针对本方法改写恢复过程。PaRaMS[2] 使用完整官方默认实现作为防御基线。

防御二的构造只读取目标专家、公开基座和两者的任务向量，不读取图片、伙伴参数或分类成绩。防御一使用目标任务的固定校准记录确定扰动幅度，不使用伙伴模型，也不更新原专家。构造完成后才评价独立能力与融合结果。本文结果来自已固定的模型与协议；测试集此前已在研究中使用，不表述为首次盲测。

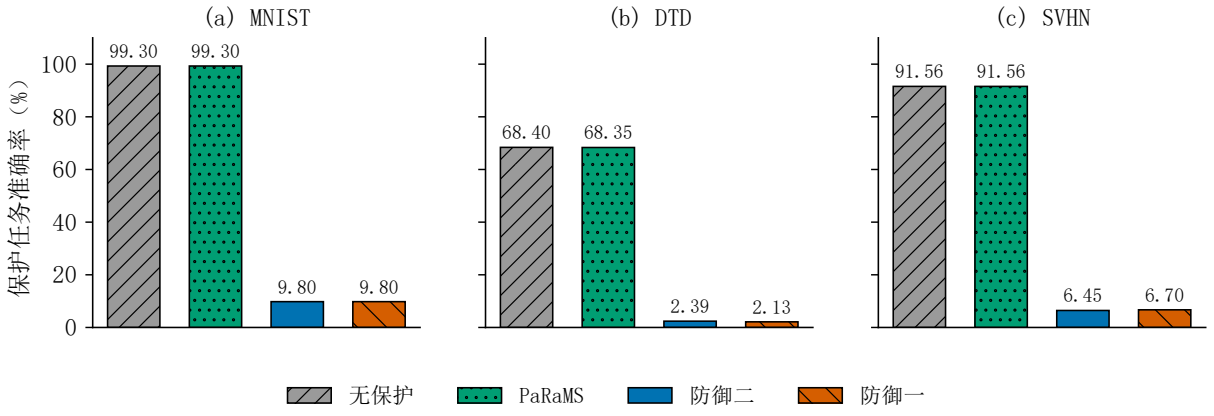


图 1　原版 AGA 仅恢复保护专家后，三个保护任务的融合准确率。较低的融合准确率对应较强的保护效果。图中均为固定模型结果，不绘制独立重复实验的误差条。

2 防御二：构造方法

2.1 以任务方向参与参数选择

对第 l 个专家矩阵 W_l 及其公开基座 $W_{0,l}$，定义任务矩阵

$$\Delta W_l = W_l - W_{0,l} = U_l \Sigma_l V_l^{\mathsf{T}}. \tag{2}$$

保留前 32 个右奇异方向，记为 $V_{l,32}$。计算范围包括 12 个 Transformer 块的 Q、K、V、Attention 输出、MLP 输入和 MLP 输出矩阵，以及输入映射和视觉投影，共 74 个矩阵。任务方向用来衡量参数改动在这些方向上的大小，不将其正交补直接解释为功能零空间。

全网络使用同一个 768 维通道排列 P。记排列引起的实际矩阵差为 $E_l(P)$，定义

$$T(P) = \sum_l \frac{\|E_l(P)\|_F^2}{\|W_l\|_F^2}, \qquad I(P) = \sum_l \frac{\|E_l(P)V_{l,32}\|_F^2}{\|W_l\|_F^2}, \tag{3}$$

$$O(P) = T(P) - I(P), \qquad F(P) = O(P) - I(P). \tag{4}$$

T 衡量整体参数变化，I 衡量任务方向上的变化，O 衡量其余方向的变化。构造最大化 F，同时考虑扩大参数变化和减小任务方向上的改动。

从恒等排列出发，每次交换两个尚未移动的通道，选择使 F 增加最多的一对；增量大于 10^{-10} 才接受，最多 384 对。增量按实际有限参数差计算，相同增量按通道编号确定顺序。它是固定贪心构造，不保证全局最优。三个主模型均使用 384 对交换；没有按测试成绩重新选排列或交换数量。

2.2 跨层同步调整，保持独立模型的计算

以列向量表示残差通道。读取该通道的 Q、K、V 和 MLP 输入矩阵改为 WP^{T}，写回该通道的 Attention 输出和 MLP 输出矩阵改为 PW。输入映射、类别和位置嵌入、LayerNorm 参数与最终视觉投影一并按相同顺序调整。Attention 头内和 MLP 隐藏单元的顺序不变。

若某一层的隐藏量由 h 变为 Ph，则相连的输入矩阵满足

$$(WP^{\mathsf{T}})(Ph) = Wh. \tag{5}$$

逐元素非线性、配套 LayerNorm 和残差加法也与排列相容。因此，整网的中间通道虽然换序，最终视觉特征在实数计算下不变。实际 FP32 模型另外完成完整任务检查；三个任务的全部测试预测均与原专家一致。

2.3 融合后的变化

原版 AGA 处理 Attention 和 MLP，未恢复全网络共同通道顺序。以输入映射为例，保护专家和伙伴的映射分别为 PW_e 与 W_p，TA 融合后为 $(PW_e + W_p)/2$。两份模型原来对应的通道不再直接对应。

对本构造 $P^2 = I$，令 $N = (I - P)/2$，可得

$$N\frac{PW_e + W_p}{2} = \frac{1}{2}N(W_p - W_e). \tag{6}$$

两模型共同的基座分量在这部分相消。该关系说明输入计算发生了什么变化，实际保护强度仍以完整分类实验为准。

3 主实验结果

表2在相同设置下比较无保护、PaRaMS、防御二和防御一，同时保留保护任务与伙伴任务准确率。防御二在三个任务上均保持原独立准确率；直接融合和原版 AGA 恢复后的保护任务准确率明显下降。PaRaMS 在直接融合时有效，但原版 AGA 能使其融合性能回到接近无保护的水平。

表 2 双专家主实验：TA 系数为 0.5，准确率（%）

保护任务 / 伙伴	方法	独立使用	直接融合	AGA 仅保护专家	AGA 双方专家
MNIST / SVHN	无保护	99.69	99.37 / 92.50	99.30 / 92.78	99.32 / 91.77
MNIST / SVHN	PaRaMS	99.69	8.92 / 9.15	99.30 / 92.79	99.32 / 91.77
MNIST / SVHN	防御二	99.69	10.98 / 14.32	9.80 / 9.81	9.80 / 9.83
MNIST / SVHN	防御一	99.69	9.80 / 6.70	9.80 / 6.70	9.80 / 6.70
DTD / MNIST	无保护	79.41	69.31 / 99.45	68.40 / 99.45	68.78 / 99.42
DTD / MNIST	PaRaMS	79.41	2.07 / 8.92	68.35 / 99.45	68.78 / 99.42
DTD / MNIST	防御二	79.41	2.39 / 10.29	2.39 / 10.09	2.39 / 10.09
DTD / MNIST	防御一	79.41	2.13 / 21.09	2.13 / 21.09	2.13 / 21.05
SVHN / MNIST	无保护	97.46	92.50 / 99.37	91.56 / 99.39	91.77 / 99.32
SVHN / MNIST	PaRaMS	97.46	9.09 / 8.95	91.56 / 99.39	91.77 / 99.32
SVHN / MNIST	防御二	97.46	7.30 / 9.45	6.45 / 12.19	6.45 / 12.22
SVHN / MNIST	防御一	97.46	6.70 / 9.80	6.70 / 9.80	6.70 / 9.80

融合列均为“保护任务 / 伙伴任务”；独立列只列保护任务。每种恢复方式分别使用其对应的无保护结果。PaRaMS 使用完整官方默认配置。

除上述组合外，同一三份防御二发布模型还完成了其余伙伴组合的评价，没有因伙伴改变而重新构造保护参数。

表 3 其余三组保护方向的完整结果，准确率（%）

保护任务 / 伙伴	方法	直接融合	AGA 仅保护专家	AGA 双方专家
MNIST / DTD	无保护	99.45 / 69.31	99.43 / 69.41	99.42 / 68.78
MNIST / DTD	防御二	5.01 / 1.81	9.80 / 2.18	9.80 / 2.18
DTD / SVHN	无保护	70.59 / 95.36	69.15 / 95.44	69.52 / 94.18
DTD / SVHN	防御二	2.93 / 8.85	2.34 / 6.42	2.34 / 6.42
SVHN / DTD	无保护	95.36 / 70.59	94.09 / 70.74	94.18 / 69.52
SVHN / DTD	防御二	7.22 / 2.13	6.53 / 2.07	6.51 / 2.07

每格为“保护任务 / 伙伴任务”。与主表合计六个保护方向，对应三个无序任务组合。

4 任务方向与修改幅度的作用

4.1 去掉任务方向项

消融保持相同矩阵范围、奇异方向数、贪心规则和交换数量，只将目标从 $T - 2I$ 改为仅最大化 T。两种顺序都已固定，表4保留全部结果。

表 4 任务方向项的消融：保护任务准确率（%）

保护任务 / 伙伴	选择目标	独立使用	直接融合	AGA 仅目标	AGA 双方
MNIST / SVHN	任务方向与距离	99.69	10.98	9.80	9.80
MNIST / SVHN	仅距离	99.69	13.99	11.27	11.08
DTD / MNIST	任务方向与距离	79.41	2.39	2.39	2.39
DTD / MNIST	仅距离	79.41	1.44	2.02	1.97
SVHN / MNIST	任务方向与距离	97.46	7.30	6.45	6.45
SVHN / MNIST	仅距离	97.46	9.36	8.52	8.48

同一贪心规则、74 个矩阵、32 个任务奇异方向和 384 对交换。只改变构造目标；各目标的原始结果均保留。

相较于仅距离目标，加入任务方向后，三个任务的任务方向内平方改动分别减少 16.83%、17.69% 和 18.27%。原版 AGA 仅恢复保护专家时，MNIST 和 SVHN 的融合准确率分别再降低 1.47 和 2.07 个百分点；DTD 则高 0.37 个百分点。任务方向项确实影响了参数选择，但分类收益没有在三个任务上一致出现，不能将全部保护效果归因于 SVD 项。

4.2 固定顺序下增加交换数量

采用同一顺序的前 96、192 和 384 对交换，比较不同修改幅度。全部档位的完整 MNIST 独立准确率均为 99.69%，测试预测不变。

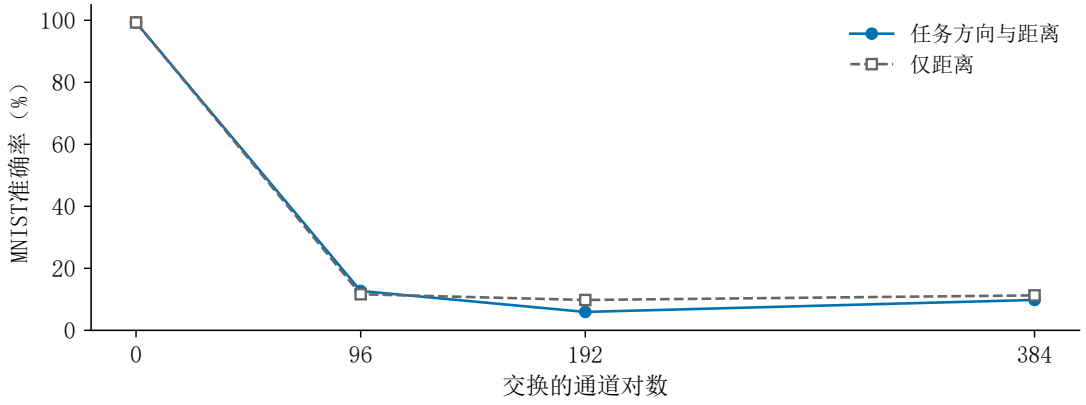


图 2 MNIST 保护、SVHN 伙伴，TA 系数 0.5，原版 AGA 仅恢复保护专家。横轴只改变同一固定顺序的交换数量；0 表示无保护。所有档位单独使用时的准确率均保持。

任务方向构造在 96、192、384 对交换时，原版 AGA 后的目标准确率分别为 12.70%、5.93% 和 9.80%。增加参数改动不带来单调增强的保护。主实验继续使用原先固定的 384 对模型，192 对仅作为消融结果，不据此更换主模型。

5 防御一：视觉投影零空间中的偏置扰动

5.1 构造及作用位置

设最终 LayerNorm 输出为行向量，视觉投影为 P_e。最终未归一化视觉特征为

$$t(h) = \left(\gamma_e \odot \frac{h - \mu(h)}{\sigma(h)} + \beta_e\right) P_e. \tag{7}$$

只修改偏置 β_e，取扰动 δ 满足

$$\widetilde{\beta}_e = \beta_e + \delta, \qquad \delta P_e = 0. \tag{8}$$

因此独立模型的视觉特征在实数计算下保持。CLIP ViT-B/32 的投影由 768 维到 512 维，提供非平凡零空间；实际按 SVD 数值秩确定。

实现先由 P_e 求零空间基，再利用目标专家与公开基座的固定插值模型确定扰动方向，以目标任务固定校准记录确定幅度。随后保存唯一偏置参数。除该偏置外，其他专家参数不变；不重新训练专家，不读取真实伙伴，也不按测试结果修改幅度。这是有结构限制的加性扰动，不是给任意参数加入独立噪声。

双专家 TA 系数为 0.5 时，最终投影同时变为 $P_{\mathrm{m}} = (P_e + P_p)/2$。相较于未保护融合模型，偏置扰动的额外特征项为

$$\frac{1}{2}\delta P_{\mathrm{m}} = \frac{1}{4}\delta P_p. \tag{9}$$

它不再由 $\delta P_e = 0$ 消去。表2中，三个任务独立准确率保持，原版 AGA 后的保护任务准确率为 9.80%、2.13% 和 6.70%。原版 AGA 没有修改最终 LayerNorm 偏置，因此这部分扰动被保留。

5.2 其他融合方法的补充结果

表 5 防御一的融合方法补充：原版 AGA 仅处理保护专家

融合方法	无保护	防御一
TA	99.30 / 92.78	9.80 / 6.70
TIES	99.32 / 94.81	9.82 / 9.69
DARE+TA	99.30 ± 0.00 / 92.81 ± 0.04	24.20 ± 5.60 / 25.50 ± 10.30
NUFILT：MNIST 先	99.39 / 94.68	99.39 / 94.68
NUFILT：SVHN 先	99.07 / 95.35	99.07 / 95.35
ProDistill	99.42 / 96.83	9.80 / 6.70

每格为 MNIST / SVHN 准确率（%）。DARE+TA 为种子 42、43、44 的均值 ± 样本标准差；各项使用匹配的无保护结果。ProDistill 为使用无标签校准图的两专家适配。

防御一在 TA、TIES、DARE+TA 及当前 ProDistill 适配下均降低了目标融合准确率。NUFILT 的当前实现不合并被修改的最终偏置，两种顺序均未保留这一防御作用。此处区分融合规则和恢复攻击，不把不同融合算法计为新的攻击种类。

6 八专家实验与结果范围

八个参与专家按 SUN397、Cars、RESISC45、EuroSAT、SVHN、GTSRB、MNIST、DTD 的固定顺序、TA 系数 0.2 合并。使用同一三份防御二发布模型，原版 AGA 只恢复保护专家，没有重新选择排列或参数。

表 6 八专家融合：TA 系数为 0.2，保护任务准确率（%）

保护任务	无保护 TA	防御二 TA	无保护 +AGA	防御二 +AGA
MNIST	94.00	10.26	93.23	11.35
DTD	52.18	3.24	51.38	4.89
SVHN	74.42	13.28	72.53	11.64

AGA 只处理保护专家。八个专家参与合并，但只评价 MNIST、DTD、SVHN，不报告八数据集平均。

八专家参与时，防御二在已评价的三个任务上仍降低了原版 AGA 后的目标准确率。该设置同时改变专家数量和融合系数，不能把差异全部解释为某一个因素。完整八数据集评价不在本表范围内。

6.1 攻击者已知信息

主结果对应不知道具体防御方式的原版 AGA。若攻击者另外知道全网络通道置换这一修改方式，利用发布模型与公开基座进行输入映射匹配，可以还原当前防御二；无需原专家、秘密排列或图片。三个模型均已逐张量核对还原，恢复后的结果对应原专家的已有分数。防御一在已知最终偏置位置的清理操作下也可恢复。这些结果限定了当前方法的结论范围，不与原版 AGA 合并报告。

6.2 实验完成情况与后续工作

当前有效结果包括：三个任务的完整独立能力检查、双专家 TA 与原版 AGA、六个保护方向、任务方向和幅度消融，以及八专家参与的三任务评价。主要记录已核对官方标签、逐类正确数、同一图片的预测变化，并用原 128 张批次上下文重放选定分数。相关模型、原始分数、源码版本及配置指纹均有保留，本次整理没有重新运行这些实验。

防御二目前通过参数置换保持原函数，任务 SVD 参与排列选择。进一步的核心工作是研究不依赖真实训练图的数值联合补偿：在任务方向少变的同时，扩大有功能作用的参数变化，并使这种补偿在融合后失效。现有数值探索尚不作为已完成的无数据方法列入主结果。后续优先完成这一构造及其必要验证。

结果来源 本报告各表由项目统一实验表及其原始记录整理，另附同源 Markdown 表格和数值文件，可与原始实验记录核对。

参考文献

[1] Guo K, Zheng Q, Liang J, et al. On the Vulnerability of Parameter-Level Defenses to Model Merging. arXiv:2606.30360, 2026. https://arxiv.org/abs/2606.30360.

[2] Wei J, Yu Z, Sakuma J. Disrupting Model Merging: A Parameter-Level Defense Without Sacrificing Accuracy. ICCV, 2025. https://arxiv.org/abs/2503.07661.

[3] Ilharco G, Ribeiro M T, Wortsman M, et al. Editing Models with Task Arithmetic. ICLR, 2023. https://arxiv.org/abs/2212.04089.