# 模型融合保护方法研究进展

2026 年 10 月 23 日

## 1 研究问题与实验设置

目标是在不重新训练原专家的条件下处理其参数：发布模型单独使用时仍能完成原任务，未经授权与其他专家融合后，受保护任务的准确率显著下降。设公开基座、目标专家、伙伴专家和发布模型分别为 $\theta_0, \theta_e, \theta_p, \widetilde{\theta}_e$。独立能力与融合保护分别通过完整测试集评价，不以参数距离代替准确率。

主实验采用 Task Arithmetic（TA）[3]：

$$\theta_{\mathrm{m}} = \theta_0 + \lambda\big[(\widetilde{\theta}_e - \theta_0) + (\theta_p - \theta_0)\big], \qquad \lambda = 0.5. \tag{1}$$

双专家情形因此等于两份专家参数的平均。所有方法使用相同的 CLIP ViT-B/32 骨干、分类头和完整测试划分。

**表 1** 任务与评价规模

| 数据集 | 任务 | 类别数 | 完整测试样本数 |
|---|---|---|---|
| MNIST | 手写数字 | 10 | 10,000 |
| DTD | 纹理分类 | 47 | 1,880 |
| SVHN | 街景数字 | 10 | 26,032 |

原版 AGA[1] 可以访问发布模型和公开基座，不预先知道所用防御。评价分为三列：直接融合；只恢复保护专家后融合；对双方专家分别恢复后融合。AGA 源码固定在作者仓库的 `fb61429` 提交，没有针对本方法改写恢复过程。PaRaMS[2] 使用完整官方默认实现作为防御基线。

**防御二：基于任务子空间的全网络通道置换。**构造只读取目标专家与公开基座，用任务 SVD 选择通道交换顺序，再同步调整各层相连参数；不读取图片、伙伴参数或分类成绩。下文图表中简称“防御二”。防御一使用目标任务的固定校准记录确定偏置扰动幅度。两者均不重新训练专家。模型固定后再评价独立能力与融合结果；测试集此前已在研究中使用，不表述为首次盲测。

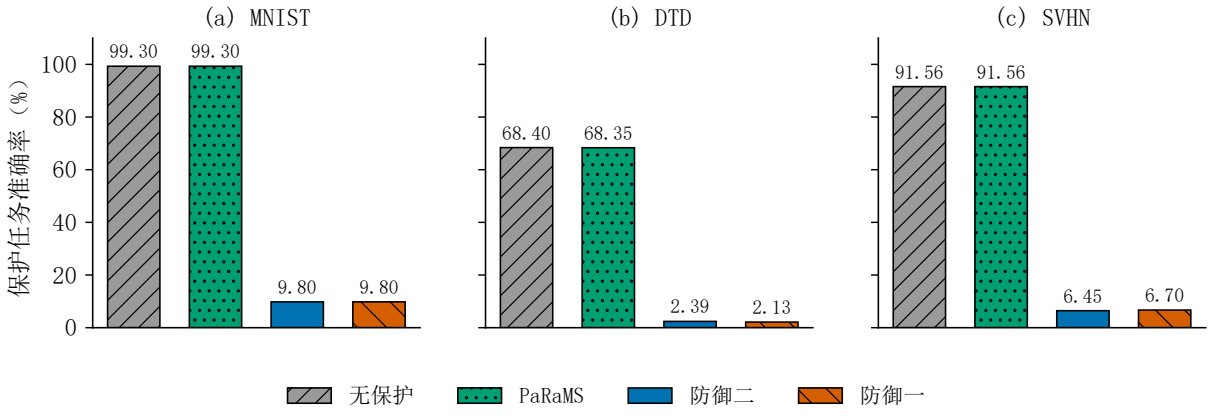



**图 1** 原版 AGA 仅恢复保护专家后，三个保护任务的融合准确率。较低的融合准确率对应较强的保护效果。图中均为固定模型结果，不绘制独立重复实验的误差条。

## 2 防御二：基于任务子空间的全网络通道置换

本方法改变视觉网络中 768 个残差通道的顺序，并同步修改各层相连参数。这里的通道是中间特征的坐标，不是类别、Attention 头或 MLP 隐藏单元。**任务 SVD 用来选择交换哪些通道；全网络同步置换用来保持原模型的计算。**

### 2.1 先用任务方向选择通道交换

对任务矩阵 $\Delta W_l = W_l - W_{0,l}$ 做 SVD，其中 $W_l$ 和 $W_{0,l}$ 分别为专家与基座参数；取前 32 个右奇异方向 $V_{l,32}$。范围为 12 个 Transformer 块的 Q、K、V、Attention 输出、MLP 输入和输出，以及输入映射和视觉投影，共 74 个矩阵。设共同排列为 $P$，实际矩阵改动为 $E_l(P)$，计算

$$T(P) = \sum_l \frac{\|E_l(P)\|_F^2}{\|W_l\|_F^2}, \qquad I(P) = \sum_l \frac{\|E_l(P)V_{l,32}\|_F^2}{\|W_l\|_F^2}, \tag{2}$$

$$F(P) = \underbrace{[T(P) - I(P)]}_{\text{任务方向外的变化}} - \underbrace{I(P)}_{\text{任务方向内的变化}}. \tag{3}$$

目标是增大方向外的变化、减小方向内的变化。从原顺序开始，每次在未交换的通道中，选使 $F$ 增加最多的一对；增量大于 $10^{-10}$ 才接受，最多 384 对，相同增量按编号决定。三个主模型均固定 384 对，不用图片或分类成绩选择。这是贪心构造，不保证全局最优。

### 2.2 再同步修改全网相连参数

以列向量表示通道：Q、K、V 和 MLP 输入矩阵改为 $WP^{\mathsf{T}}$，Attention 输出和 MLP 输出矩阵改为 $PW$；输入映射、对应偏置、嵌入和 LayerNorm 参数也按同一顺序调整，最终投影还原输出坐标。因此

$$(WP^{\mathsf{T}})(Ph) = Wh. \tag{4}$$

例如把第 1、3 通道互换，就同时互换下一矩阵的第 1、3 列（图2）。残差两支使用同一排列，LayerNorm 和逐元素非线性也保持对应，逐层计算由此保持。**独立功能保持来自这种配套修改，而不是假定 SVD 方向外没有功能作用。**完整 FP32 测试中，三个任务的全部预测均与原专家一致。

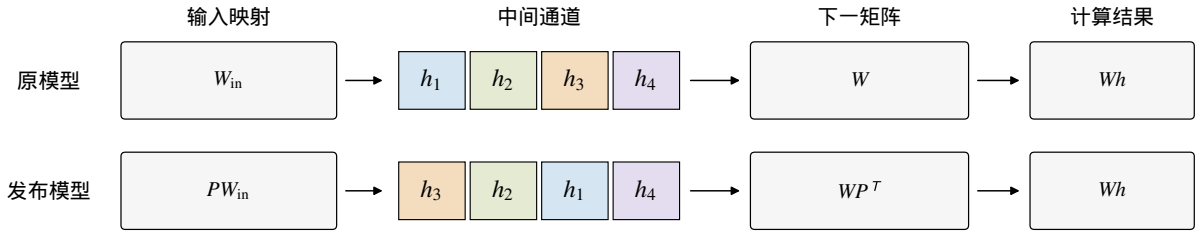



**图 2** 一次通道交换的示意。输入映射与后续矩阵同时调整，右端计算结果保持。实际模型对全网络使用同一排列，而非只修改图中的两个矩阵。

### 2.3 融合后，原来的对应关系被打乱

伙伴保留自己的通道顺序。以输入映射为例，TA 将 $PW_e$ 与 $W_p$ 按位置平均，得到 $(PW_e + W_p)/2$；后续矩阵也分别平均，两端原有的配套关系因而不再自动成立。原版 AGA 处理 Attention 和 MLP，没有完成全网共同排列的恢复。下一页报告实际分类结果，保护强度由这些结果检验。

## 3 主实验结果

表2在相同设置下比较无保护、PaRaMS、防御二和防御一，同时保留保护任务与伙伴任务准确率。防御二在三个任务上均保持原独立准确率；直接融合和原版 AGA 恢复后的保护任务准确率明显下降。PaRaMS 在直接融合时有效，但原版 AGA 能使其融合性能回到接近无保护的水平。

**表 2** 双专家主实验：TA 系数为 0.5，准确率（%）

| 保护任务 / 伙伴 | 方法 | 独立使用 | 直接融合 | AGA 仅保护专家 | AGA 双方专家 |
|---|---|---|---|---|---|
| MNIST / SVHN | 无保护 | 99.69 | 99.37 / 92.50 | 99.30 / 92.78 | 99.32 / 91.77 |
| MNIST / SVHN | PaRaMS | 99.69 | 8.92 / 9.15 | 99.30 / 92.79 | 99.32 / 91.77 |
| MNIST / SVHN | 防御二 | 99.69 | 10.98 / 14.32 | 9.80 / 9.81 | 9.80 / 9.83 |
| MNIST / SVHN | 防御一 | 99.69 | 9.80 / 6.70 | 9.80 / 6.70 | 9.80 / 6.70 |
| DTD / MNIST | 无保护 | 79.41 | 69.31 / 99.45 | 68.40 / 99.45 | 68.78 / 99.42 |
| DTD / MNIST | PaRaMS | 79.41 | 2.07 / 8.92 | 68.35 / 99.45 | 68.78 / 99.42 |
| DTD / MNIST | 防御二 | 79.41 | 2.39 / 10.29 | 2.39 / 10.09 | 2.39 / 10.09 |
| DTD / MNIST | 防御一 | 79.41 | 2.13 / 21.09 | 2.13 / 21.09 | 2.13 / 21.05 |
| SVHN / MNIST | 无保护 | 97.46 | 92.50 / 99.37 | 91.56 / 99.39 | 91.77 / 99.32 |
| SVHN / MNIST | PaRaMS | 97.46 | 9.09 / 8.95 | 91.56 / 99.39 | 91.77 / 99.32 |
| SVHN / MNIST | 防御二 | 97.46 | 7.30 / 9.45 | 6.45 / 12.19 | 6.45 / 12.22 |
| SVHN / MNIST | 防御一 | 97.46 | 6.70 / 9.80 | 6.70 / 9.80 | 6.70 / 9.80 |

融合列均为“保护任务 / 伙伴任务”；独立列只列保护任务。每种恢复方式分别使用其对应的无保护结果。PaRaMS 使用完整官方默认配置。

除上述组合外，同一三份防御二发布模型还完成了其余伙伴组合的评价，没有因伙伴改变而重新构造保护参数。

**表 3** 其余三组保护方向的完整结果，准确率（%）

| 保护任务 / 伙伴 | 方法 | 直接融合 | AGA 仅保护专家 | AGA 双方专家 |
|---|---|---|---|---|
| MNIST / DTD | 无保护 | 99.45 / 69.31 | 99.43 / 69.41 | 99.42 / 68.78 |
| MNIST / DTD | 防御二 | 5.01 / 1.81 | 9.80 / 2.18 | 9.80 / 2.18 |
| DTD / SVHN | 无保护 | 70.59 / 95.36 | 69.15 / 95.44 | 69.52 / 94.18 |
| DTD / SVHN | 防御二 | 2.93 / 8.85 | 2.34 / 6.42 | 2.34 / 6.42 |
| SVHN / DTD | 无保护 | 95.36 / 70.59 | 94.09 / 70.74 | 94.18 / 69.52 |
| SVHN / DTD | 防御二 | 7.22 / 2.13 | 6.53 / 2.07 | 6.51 / 2.07 |

每格为“保护任务 / 伙伴任务”。与主表合计六个保护方向，对应三个无序任务组合。

# 4 任务方向与修改幅度的作用

## 4.1 去掉任务方向项

消融保持相同矩阵范围、奇异方向数、贪心规则和交换数量，只将目标从 $T - 2I$ 改为仅最大化 $T$。两种顺序都已固定，表4保留全部结果。

**表 4** 任务方向项的消融：保护任务准确率（%）

| 保护任务 / 伙伴 | 选择目标 | 独立使用 | 直接融合 | AGA 仅目标 | AGA 双方 |
|---|---|---|---|---|---|
| MNIST / SVHN | 任务方向与距离 | 99.69 | 10.98 | 9.80 | 9.80 |
| MNIST / SVHN | 仅距离 | 99.69 | 13.99 | 11.27 | 11.08 |
| DTD / MNIST | 任务方向与距离 | 79.41 | 2.39 | 2.39 | 2.39 |
| DTD / MNIST | 仅距离 | 79.41 | 1.44 | 2.02 | 1.97 |
| SVHN / MNIST | 任务方向与距离 | 97.46 | 7.30 | 6.45 | 6.45 |
| SVHN / MNIST | 仅距离 | 97.46 | 9.36 | 8.52 | 8.48 |

同一贪心规则、74 个矩阵、32 个任务奇异方向和 384 对交换。只改变构造目标；各目标的原始结果均保留。

相较于仅距离目标，加入任务方向后，三个任务的任务方向内平方改动分别减少 16.83%、17.69% 和 18.27%。原版 AGA 仅恢复保护专家时，MNIST 和 SVHN 的融合准确率分别再降低 1.47 和 2.07 个百分点；DTD 则高 0.37 个百分点。任务方向项确实影响了参数选择，但分类收益没有在三个任务上一致出现，不能将全部保护效果归因于 SVD 项。

## 4.2 固定顺序下增加交换数量

采用同一顺序的前 96、192 和 384 对交换，比较不同修改幅度。全部档位的完整 MNIST 独立准确率均为 99.69%，测试预测不变。

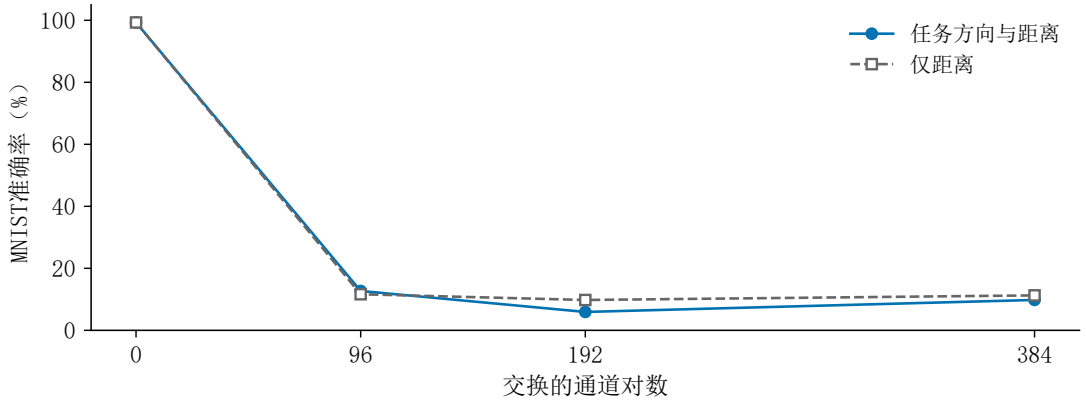



**图 3** MNIST 保护、SVHN 伙伴，TA 系数 0.5，原版 AGA 仅恢复保护专家。横轴只改变同一固定顺序的交换数量；0 表示无保护。所有档位单独使用时的准确率均保持。

任务方向构造在 96、192、384 对交换时，原版 AGA 后的目标准确率分别为 12.70%、5.93% 和 9.80%。增加参数改动不带来单调增强的保护。主实验继续使用原先固定的 384 对模型，192 对仅作为消融结果，不据此更换主模型。

## 5 防御一：视觉投影零空间中的偏置扰动

### 5.1 构造及作用位置

设最终 LayerNorm 输出为行向量，视觉投影为 $P_e$。最终未归一化视觉特征为

$$t(h) = \left(\gamma_e \odot \frac{h - \mu(h)}{\sigma(h)} + \beta_e\right) P_e. \tag{5}$$

只修改偏置 $\beta_e$，取扰动 $\delta$ 满足

$$\widetilde{\beta}_e = \beta_e + \delta, \qquad \delta P_e = 0. \tag{6}$$

因此独立模型的视觉特征在实数计算下保持。CLIP ViT-B/32 的投影由 768 维到 512 维，提供非平凡零空间；实际按 SVD 数值秩确定。

实现先由 $P_e$ 求零空间基，再利用目标专家与公开基座的固定插值模型确定扰动方向，以目标任务固定校准记录确定幅度。随后保存唯一偏置参数。除该偏置外，其他专家参数不变；不重新训练专家，不读取真实伙伴，也不按测试结果修改幅度。这是有结构限制的加性扰动，不是给任意参数加入独立噪声。

双专家 TA 系数为 0.5 时，最终投影同时变为 $P_{\mathrm{m}} = (P_e + P_p)/2$。相较于未保护融合模型，偏置扰动的额外特征项为

$$\frac{1}{2}\delta P_{\mathrm{m}} = \frac{1}{4}\delta P_p. \tag{7}$$

它不再由 $\delta P_e = 0$ 消去。表2中，三个任务独立准确率保持，原版 AGA 后的保护任务准确率为 9.80%、2.13% 和 6.70%。原版 AGA 没有修改最终 LayerNorm 偏置，因此这部分扰动被保留。

### 5.2 其他融合方法的补充结果

**表 5** 防御一的融合方法补充：原版 AGA 仅处理保护专家

| 融合方法 | 无保护 | 防御一 |
|---|---|---|
| TA | 99.30 / 92.78 | 9.80 / 6.70 |
| TIES | 99.32 / 94.81 | 9.82 / 9.69 |
| DARE+TA | 99.30 ± 0.00 / 92.81 ± 0.04 | 24.20 ± 5.60 / 25.50 ± 10.30 |
| NUFILT：MNIST 先 | 99.39 / 94.68 | 99.39 / 94.68 |
| NUFILT：SVHN 先 | 99.07 / 95.35 | 99.07 / 95.35 |
| ProDistill | 99.42 / 96.83 | 9.80 / 6.70 |

每格为 MNIST / SVHN 准确率（%）。DARE+TA 为种子 42、43、44 的均值 ± 样本标准差；各项使用匹配的无保护结果。ProDistill 为使用无标签校准图的两专家适配。

防御一在 TA、TIES、DARE+TA 及当前 ProDistill 适配下均降低了目标融合准确率。NUFILT 的当前实现不合并被修改的最终偏置，两种顺序均未保留这一防御作用。此处区分融合规则和恢复攻击，不把不同融合算法计为新的攻击种类。

## 6 八专家实验与结果范围

八个参与专家按 SUN397、Cars、RESISC45、EuroSAT、SVHN、GTSRB、MNIST、DTD 的固定顺序、TA 系数 0.2 合并。使用同一三份防御二发布模型，原版 AGA 只恢复保护专家，没有重新选择排列或参数。

**表 6** 八专家融合：TA 系数为 0.2，保护任务准确率（%）

| 保护任务 | 无保护 TA | 防御二 TA | 无保护 +AGA | 防御二 +AGA |
|---|---|---|---|---|
| MNIST | 94.00 | 10.26 | 93.23 | 11.35 |
| DTD | 52.18 | 3.24 | 51.38 | 4.89 |
| SVHN | 74.42 | 13.28 | 72.53 | 11.64 |

AGA 只处理保护专家。八个专家参与合并，但只评价 MNIST、DTD、SVHN，不报告八数据集平均。

八专家参与时，防御二在已评价的三个任务上仍降低了原版 AGA 后的目标准确率。该设置同时改变专家数量和融合系数，不能把差异全部解释为某一个因素。完整八数据集评价不在本表范围内。

### 6.1 攻击者已知信息

主结果对应不知道具体防御方式的原版 AGA。若攻击者另外知道全网络通道置换这一修改方式，利用发布模型与公开基座进行输入映射匹配，可以还原当前防御二；无需原专家、秘密排列或图片。三个模型均已逐张量核对还原，恢复后的结果对应原专家的已有分数。防御一在已知最终偏置位置的清理操作下也可恢复。这些结果限定了当前方法的结论范围，不与原版 AGA 合并报告。

### 6.2 实验完成情况与后续工作

当前有效结果包括：三个任务的完整独立能力检查、双专家 TA 与原版 AGA、六个保护方向、任务方向和幅度消融，以及八专家参与的三任务评价。主要记录已核对官方标签、逐类正确数、同一图片的预测变化，并用原 128 张批次上下文重放选定分数。相关模型、原始分数、源码版本及配置指纹均有保留，本次整理没有重新运行这些实验。

防御二目前通过参数置换保持原函数，任务 SVD 参与排列选择。进一步的核心工作是研究不依赖真实训练图的数值联合补偿：在任务方向少变的同时，扩大有功能作用的参数变化，并使这种补偿在融合后失效。现有数值探索尚不作为已完成的无数据方法列入主结果。后续优先完成这一构造及其必要验证。

**结果来源** 本报告各表由项目统一实验表及其原始记录整理，另附同源 Markdown 表格和数值文件，可与原始实验记录核对。

## 参考文献

[1] Guo K, Zheng Q, Liang J, et al. On the Vulnerability of Parameter-Level Defenses to Model Merging. arXiv:2606.30360, 2026. https://arxiv.org/abs/2606.30360.

[2] Wei J, Yu Z, Sakuma J. Disrupting Model Merging: A Parameter-Level Defense Without Sacrificing Accuracy. ICCV, 2025. https://arxiv.org/abs/2503.07661.

[3] Ilharco G, Ribeiro M T, Wortsman M, et al. Editing Models with Task Arithmetic. ICLR, 2023. https://arxiv.org/abs/2212.04089.