Post-hoc Model Merge Protection

模型融合的后处理防御

两种方案与攻击评估

CLIP ViT-B/32 RTX 3090

2026 年 10 月 16 日

研究问题

专家独立使用时保持能力，未经授权融合后降低被保护任务性能。

$$\theta_{\text{release}} = T_c(\theta_e), \qquad \theta_{\text{merge}} = \theta_0 + \tfrac{1}{2}\big[(\theta_{\text{release}} - \theta_0) + (\theta_p - \theta_0)\big].$$

- 已微调专家 θ_e 冻结；保护发生在模型发布前。
- 构造仅使用目标专家、公开基座及目标训练数据，不读取未来伙伴。
- 同时评价**被保护任务与伙伴任务**，区分融合和攻击恢复。

两套方案：**投影核空间偏置扰动**；**任务子空间约束的跨模块补偿。**

评价使用历史测试集，冻结防御后执行；不将其称为首次盲测。TA 为 Task Arithmetic。

方案一：投影核空间中的偏置扰动

CLIP 末端特征为 $t = \mathrm{LN}_{\gamma,b}(h)P_e$，$P_e \in \mathbb{R}^{768\times512}$。选择

$$v^\top P_e = 0, \qquad b' = b + \alpha v \quad \Longrightarrow \quad t' = t.$$

独立模型不读取该方向；融合后读出矩阵改变，扰动变为 $\delta t_{\mathrm{merge}} = \frac{\alpha}{2} v^\top P_{\mathrm{merge}}$。

被保护任务	独立	无保护 AGA 后	保护 AGA 后
MNIST	99.69	99.32	9.80
DTD	79.41	68.78	2.13
SVHN	97.46	91.77	6.70

AGA 原版未修改关键 LN 偏置；这些结果不能证明抗任意恢复。

准确率（%）；AGA 处理全部参与专家。该方案与第二方案的 0.5 距离预算分列，不能直接作同预算优劣比较。来源：results/phase3/results.json。

方案二：任务子空间约束下的跨模块补偿

对任务矩阵 $\Delta W = W_e - W_0 = U\Sigma V^\top$ 构造奇异方向探针，仅求解发布变换系数 c。

$$\max_c D(T_c(\theta_e), \theta_e) \quad \text{s.t.} \quad D \le 0.5, \quad R_{\mathcal{C}\cup\mathcal{P}}(c) \le 0.5.$$

- R：自然训练输入与奇异探针上的最坏相对分类间隔变化。
- 内层选择最坏任务输入 / 竞争类别；外层在有限可行域内增大参数距离，并使用公开基座代理诊断分类响应。
- O/B 联合修改 Attention 输出和 MLP 输出；A/B 联合修改 MLP 输入和输出。

原任务中的联合补偿，可能在融合后的表示与门控变化下失配。

SVD 是结构工具，不是功能保持证明；有限内层与公开代理不构成未知伙伴下的安全保证。使用发布系数梯度，不能称零训练成本。

真实融合与 AGA 结果

MNIST 为被保护任务，SVHN 为伙伴；每格为 **MNIST / SVHN** 准确率（%）。

方法	独立 MNIST	直接融合	AGA 处理保护专家	AGA 处理全部专家
无保护	99.69	99.37 / 92.50	99.30 / 92.78	99.32 / 91.77
偏置扰动 *	99.69	9.80 / 6.70	9.80 / 6.70	9.80 / 6.70
补偿 O/B†	99.71	78.77 / 62.94	79.53 / 65.82	77.85 / 61.42
补偿 A/B†	99.65	91.07 / 77.46	85.42 / 75.50	79.20 / 69.84
PaRaMS*	99.69	8.92 / 9.15	99.30 / 92.79	99.32 / 91.77

PaRaMS 完整配置的直接融合破坏可被 AGA 恢复。O/B、A/B 的干扰仍然存在，但需要单独核验功能约束。

TA 系数 0.5；两列 AGA 分别处理保护专家、全部专家。* 不同预算参考；† 已发现任务保持预算反例。PaRaMS 为完整官方配置。

准确率保持，不等于最坏功能误差合格

实现	参数距离	最大间隔漂移	越界样本	任务约束
O/B	0.29904	5.36907	1/512	超过 0.5
A/B	0.36414	39.92018	1/512	超过 0.5

同一训练样本的教师 7/9 分数间隔仅为 0.02034：

- O/B 使该间隔增大，预测仍为 7；相对漂移仍超过 0.5。
- A/B 使间隔变为负值，预测由 7 变为 9；同样违反约束。

两者保留为真实效果参考，不能宣称全任务满足双 0.5 预算。

固定 512 张训练图的只读审计；完整模型重放误差为 0。历史有限确认保留，不使用暴露见证修补权重。来源：utility.json、utility_witnesses.json。

攻击方法：依据、权限与复现状态

攻击 / 恢复流程	关键权限与操作	当前状态
AGA	公开基座；Attention 求解 + MLP 匹配	官方代码已复现
PaRaMS 自适应恢复	基座与防御知识；恢复排列 / 尺度	MLP 官方对齐入口已核对；未运行
MergeLock 配对对齐	伙伴参照；Q/K、V/O 耦合正交对齐	原文核对；官方库仅 README
MergeBarrier 解码 / 层替换	基座、变换 / 修改位置知识	原文与附录核对；替换仅历史诊断
Unmask / GradErase	参数减法 / 任务数据 + 投影梯度再训练	正式论文核对；未复现
蒸馏、融合后 SFT	教师查询 / 任务数据与额外训练	未运行；强权限单列
ProDistill 用于恢复	校准输入 + 逐层特征蒸馏，学习融合系数	官方 Vision 代码已读；未运行

TA、TIES、NUFILT 是融合算法。攻击后可以接不同融合算法，但不把它们计为新增恢复攻击。

PaRaMS §6；MergeLock §4.2.2；MergeBarrier §4.1、附录 D；MergeGuard §7；Trap² §6.4。完整链接与固定源码见 notes/phase3_attack_review.md。

更换融合算法后的保护边界

NUFILT 原作者内核 + 现有 CLIP 权重适配；保护 MNIST，伙伴 SVHN。两个任务顺序均评价，下面展示 MNIST 先加入的固定顺序。

方法	无攻击	AGA 处理保护专家	AGA 处理全部专家
无保护	99.43 / 94.45	99.39 / 94.68	99.39 / 93.75
偏置扰动	99.43 / 94.45	99.39 / 94.68	99.39 / 93.75
补偿 A/B†	99.33 / 94.46	99.14 / 94.61	99.08 / 93.72

- 其默认合并不读取关键 LN 偏置，方案一与对应无保护合并模型相同。
- 两个顺序中，A/B 距匹配无保护 MNIST 控制仅 0.06–0.31 个百分点。

每格为 MNIST / SVHN 准确率（%）。无图片参与融合门控求解；原专家和防御不更新。此处是融合方法评价，不是新增攻击；未复现完整 FusionBench 论文表。

当前结论与后续实验

- **两种机制均观察到真实融合干扰。**
  方案一有跨被保护任务结果；方案二仍主要限于 MNIST。
- **安全边界已经明确。**
  方案一依赖融合参数覆盖；方案二存在任务预算反例，通用性与创新性尚未确立。
- **下一步补攻击证据，不改冻结防御。**
  优先补齐可核验的对齐 / 解码恢复；蒸馏和再训练按更强权限单独评价。

全部既有权重、原始预测和失败证据保留。当前完成的是固定攻击与融合设置，未宣称覆盖所有攻击。