Post-hoc Model Merge Protection

模型融合的后处理防御

两种方案与攻击评估

CLIP ViT-B/32　RTX 3090

2026 年 10 月 19 日组会（数据截至 10 月 18 日）

研究问题

专家独立使用时保持能力，未经授权融合后降低被保护任务性能。

$$\theta_{\text{release}} = T_c(\theta_e), \qquad \theta_{\text{merge}} = \theta_0 + \tfrac{1}{2}\big[(\theta_{\text{release}} - \theta_0) + (\theta_p - \theta_0)\big].$$

- 已微调专家 θ_e 冻结；保护发生在模型发布前。
- 构造仅使用目标专家、公开基座及目标训练数据，不读取未来伙伴。
- 同时评价**被保护任务与伙伴任务**，区分融合和攻击恢复。

两套方案：**投影核空间偏置扰动**；**任务子空间约束的跨模块补偿。**

评价使用历史测试集，冻结防御后执行；不将其称为首次盲测。TA 为 Task Arithmetic。

方案一：投影核空间中的偏置扰动

CLIP 末端特征为 $t = \mathrm{LN}_{\gamma,b}(h)P_e$，$P_e \in \mathbb{R}^{768\times512}$。选择

$$v^\top P_e = 0, \qquad b' = b + \alpha v \quad \Longrightarrow \quad t' = t.$$

理想算术下独立特征不变；融合后读出矩阵改变，扰动变为 $\delta t_{\mathrm{merge}} = \frac{\alpha}{2} v^\top P_{\mathrm{merge}}$。

被保护任务	独立	无保护 AGA 后	保护 AGA 后
MNIST	99.69	99.32	9.80
DTD	79.41	68.78	2.13
SVHN	97.46	91.77	6.70

AGA 原版未修改关键 LN 偏置；这些结果不能证明抗任意恢复。

准确率（%）；AGA 处理全部参与专家。该方案与第二方案的 0.5 距离预算分列，不能直接作同预算优劣比较。来源：results/phase3/results.json。

方案二：距离目标与任务内外的实际处理

任务向量 $\Delta W = W_e - W_0 = U\Sigma V^\top$；O/B 旧参数化为

$$\delta O = \|O_e\|_F U_{32} C V_{32}^\top, \qquad \delta B = \|B_e\|_F Q_{\text{cls}} K.$$

$$\max_{c} \; D(c)^2/0.5^2 + \phi_{\text{source}}(c) \quad \text{s.t.} \quad D(c) \le 0.5, \quad R_{\mathcal{C}\cup\mathcal{P}}(c) \le 0.5.$$

- 距离最大化目标已经写入；R 是完整分数的相对分类间隔变化，不是概率差。
- 上游仅开放 32 维任务 SVD 坐标；B 输入已覆盖 3072 维，输出仍受分类读出空间限制。
- 奇异方向作有限上下文探针，另用自然训练输入验收；不能当作完整功能零空间。

需要联合控制完整功能，不是简单删去任务内分量或放大噪声。

代码：angular_distance.py、boundary_game.py、ffn_game.py。有限最坏任务约束及公开基座代理，不构成未知伙伴下的完整安全博弈；仅发布系数有梯度。

真实融合与 AGA 结果

MNIST 为被保护任务，SVHN 为伙伴；每格为 **MNIST / SVHN** 准确率（%）。

方法	独立 MNIST	直接融合	AGA 处理保护专家	AGA 处理全部专家
无保护	99.69	99.37 / 92.50	99.30 / 92.78	99.32 / 91.77
偏置扰动 *	99.69	9.80 / 6.70	9.80 / 6.70	9.80 / 6.70
补偿 O/B†	99.71	78.77 / 62.94	79.53 / 65.82	77.85 / 61.42
补偿 A/B†	99.65	91.07 / 77.46	85.42 / 75.50	79.20 / 69.84
PaRaMS*	99.69	8.92 / 9.15	99.30 / 92.79	99.32 / 91.77

八专家 TA0.2	MNIST	DTD	SVHN
无保护	93.23	52.34	73.90
O/B†	54.22	50.80	44.63
A/B†	59.16	50.59	51.97

八专家表只评三任务，AGA 仅处理保护专家；参与数与系数同时变化，不能归因于单一因素。

上表 TA 系数 0.5；两列 AGA 分别处理保护专家、全部专家。* 不同预算参考；† 已发现任务保持预算反例。PaRaMS 为完整官方配置。

准确率保持，不等于最坏功能误差合格

实现	参数距离	最大间隔漂移	越界样本	任务约束
O/B	0.29904	5.36907	1/512	超过 0.5
A/B	0.36414	39.92018	1/512	超过 0.5

完整读出仍含 LN 尺度 $\sigma(h)$；$\Gamma = \mathrm{diag}(\gamma)$，$H$ 为固定分类头：

$$u(h) = \mathrm{center}(h)\Gamma P + \sigma(h)\beta P, \qquad s(h) = u(h)H^{\top}/\|u(h)\|.$$

- 教师 7/9 间隔仅 0.02034；O/B 预测未变仍越界，A/B 已有改判反例。
- 新任务外 0.5 点：源漂移 0.47384、新确认 0.45155；完整漂移仍达 5.94243，已关闭。
- 线性读出核没有控制完整 LN 方差与特征范数；更大幅度或更多层不自动解决这一问题。

两者保留为真实效果参考，不能宣称全任务满足双 0.5 预算。

固定 512 张训练图的只读审计；完整模型重放误差为 0。历史有限确认保留，不使用暴露见证修补权重。来源：utility.json、utility_witnesses.json。

攻击方法：依据、权限与复现状态

攻击 / 恢复流程	关键权限与操作	当前状态
AGA	公开基座；Attention 求解 + MLP 匹配	官方代码已复现
PaRaMS 自适应恢复	基座与防御知识；恢复排列 / 尺度	MLP 官方核 + 对角 Attention 适配已验证
MergeLock 配对对齐	伙伴参照；Q/K、V/O 耦合正交对齐	原文核对；官方库仅 README
MergeBarrier 解码 / 层替换	基座、变换 / 修改位置知识	原文与附录核对；替换仅历史诊断
Unmask / GradErase	整份参数减法 / 数据 + 投影梯度再训练	Unmask 全量未有效恢复；GradErase 未运行
偏置清理；蒸馏 / SFT	发布 P 和偏置；或教师数据与训练	清理已验证；SFT 未运行
ProDistill 用于恢复	每任务 64 张无类别标签图 + 任务归属	官方系数核两专家适配已完成

TA、TIES、DARE、NUFILT、ProDistill 是融合维度。攻击后可以接不同融合算法，但不把它们计为新增恢复攻击。

PaRaMS §6；MergeLock §4.2.2；MergeBarrier §4.1、附录 D；MergeGuard §7；Trap² §6.4。完整链接与固定源码见 notes/phase3_attack_review.md。

方案一：关键偏置未被合并时，保护被绕过

同为 AGA 仅处理保护专家；每格为目标 / 伙伴准确率（%），固定目标先加入顺序。

目标 / 伙伴	TA+AGA	NUFILT+AGA	NUFILT 无保护
MNIST / SVHN	9.80 / 6.70	99.39 / 94.68	99.39 / 94.68
DTD / MNIST	2.13 / 21.09	70.59 / 99.45	70.59 / 99.45
SVHN / MNIST	6.70 / 9.80	94.40 / 99.25	94.40 / 99.25

- NUFILT 不读取最终 LN 偏置；这些保护 / 无保护合并模型的分数逐项相同。
- 发布 P 和偏置的最小范数清理也能恢复；DTD/SVHN 用单列混合精度读出验证，原生 FP32 失败保留。
- O/B、A/B 在 AGA 后接 ProDistill 时，MNIST 均 99.42%，控制 99.42%；SVHN 仍有 0.67 / 0.37 个百分点差距。

NUFILT 为融合方法，非新恢复攻击。ProDistill 使用 64 张 / 任务、任务归属和逐元素系数梯度；最终 LN/P 未更新，因此不能将其对方案一失败称为通用抗蒸馏。

已完成什么，还差什么

- **方案一：机制与局限已有完整证据。**
  TA / AGA 下有明显干扰；偏置清理和 NUFILT 能绕过，不能只报低准确率。
- **方案二：合规有效的新方法仍未完成。**
  已完成参数内外核对与固定消融；尚未打通完整功能保持与融合有害响应。O/B、A/B 仅作效果参考。
- **攻击评价：已补任务、伙伴和知识来源控制。**
  Unmask 固定公式已核验，但无保护控制也严重退化；下一方法先解决原生结构的功能保持，再作一个最小验证。

保留所有冻结权重和失败证据；不把 SVD、参数对称性、常规 min-max 或恢复器覆盖缺口当作原创算法。完整论文 / 源码核对及未复现项均见仓库。